




Fact_videostatistics

Het doel van deze tabel is het dagelijks ophalen van de views, likes en comments van een video. Deze tabel bevat duplicaten, want je wil een historie opbouwen.

Kolommen:

- Fact_id: Unieke key
- Video_id: Id van de opgehaalde video. Verwijst naar een video in dim_video
- Channel_id: Id van het kanaal dat bij de video hoort. Verwijst naar een channel in dim_channel
- Category_id: Id van de categorie die bij de video hoort. Verwijst naar een categorie in dim_category
- Views: De views van de video op een moment
- Likes: De likes van de video op een moment
- Comments: De comments van de video op een moment
- Time_id: De tijd waarop de data is opgehaald

Dim_video

Het doel van deze tabel is om meer informatie te geven over een opgehaalde video. Hier hoeven dus geen duplicaten in te staan, want dit is een dimensie tabel.

Kolommen:

- Id: Uniek id
- Video_id: Id van een video
- Title: Titel van de video
- Published_at: Datum waarop de video is gepubliceerd
- Recording_date: Datum waarop de video is opgenomen
- Duration_sec: Duur van de video in seconden
- Resolution: De resolutie van de video
- Tags: De tags van de video
- Language: De taal van de video
- Transcript: De transcriptie van de video. Opgehaald met whisper
- Sentiment: Het sentiment
- Engagement: De engagement

Dim_channel

Het doel van de dim_channel is om meer informatie te geven over het kanaal van een opgehaalde video.

Kolommen:

- Id: Uniek id
- Name: Naam van het kanaal
- Description: De beschrijving van het kanaal
- Subscribers: Aantal abonnees
- Video_count: Aantal video's
- Views: Aantal totale weergaven van alle video's

Dim_category

Het doel van deze tabel is om een category_id te verbinden met de naam van deze categorie. Dit stond er namelijk niet standaard bij als je de metadata ophaalt.

Kolommen:

- Id: Uniek id
- Naam: Naam van de categorie

Dim_time

Het doel van deze kolom is om elke timestamp van de fact_videostatistics te ontleden in meerdere delen.

Kolommen:

- Id: Uniek id
- Timestamp: De hele timestamp die ook in de fact_videostatistics staat
- Year: Jaar
- Month: Maand
- Day: Day
- Hour: Uur
- Second: Seconden
- Day_of_week: Dag van de week(getal van 0-6)
- Quarter: Kwartaal van het jaar

Alle dimensies hebben een één-op-veel relatie met de fact tabel. Dit is ook zoals het hoort. Op deze manier kunnen er meerdere duplicaten staan in de fact tabel, terwijl dezelfde video's allemaal verwijzen naar dezelfde dimensies.

De reden dat ik heb gekozen voor deze structuur, is omdat ik zoveel mogelijk informatie wilde ophalen over de video's, terwijl ik zo min mogelijk informatie dubbel opsla. Alle data wordt per dag opgehaald in de fact_videostatistics. Deze data, waaronder de views, heb ik ook dagelijks nodig per video. Hier staan dus veel kopieën van video's in. Vervolgens wordt er per video gecheckt of alle tabellen al bestaan. Zo ja, dan hoeft deze niet nog een keer aangemaakt te worden. De dim_channel tabel heeft dus bijvoorbeeld maar 3 kanalen, omdat de video's maar van 3 kanalen worden gehaald.

Door te verwijzen naar de dim_channel of dim_video in de fact_videostatistics, kan ik dus extra informatie opslaan over de video die niet elke keer opnieuw aangemaakt hoeft te worden.